

# Contents

|       |                              |   |
|-------|------------------------------|---|
| 1     | DD13: ウィジェット配信               | 1 |
| 1.1   | 0. 文書情報                      | 1 |
| 1.2   | 1. 対象範囲                      | 1 |
| 1.3   | 2. 収録ロジック・対応章                | 1 |
| 1.4   | 3. 詳細設計本文                    | 2 |
| 1.4.1 | 3.1 ウィジェット API リクエストフロー      | 2 |
| 1.4.2 | 3.2 配信構成                     | 2 |
| 1.4.3 | 3.3 実装モジュール構成                | 2 |
| 1.4.4 | 3.4 性能目標 (NFR-101 / NFR-102) | 3 |
| 1.4.5 | 3.5 ウィジェット応答経路の最適化           | 3 |
| 1.4.6 | 3.6 AI 推論タイムアウト + フォールバック    | 3 |
| 1.4.7 | 3.7 レート制限 (FR-194 / AC-033)  | 3 |
| 1.4.8 | 3.8 SCR-027 お問い合わせ再開フロー      | 3 |
| 1.4.9 | 3.9 関連する横断設計                 | 3 |
| 1.5   | 4. 関連設計                      | 3 |
| 1.6   | 5. テスト観点                     | 4 |
| 1.6.1 | 5.1 ウィジェット E2E 例             | 4 |
| 1.6.2 | 5.2 負荷試験                     | 4 |
| 1.6.3 | 5.3 その他観点                    | 4 |
| 1.7   | 6. 未確定事項・確認事項                | 4 |

## 1 DD13: ウィジェット配信

### 1.1 0. 文書情報

| 項目      | 内容                                                                                 |
|---------|------------------------------------------------------------------------------------|
| 文書名     | DD13: ウィジェット配信                                                                     |
| 詳細設計 ID | DD13                                                                               |
| 対象システム  | FAQ AI ウィジェット SaaS / メインシステム                                                       |
| 関連機能 ID | FR-150～156 (ウィジェット設定 / 配信) / FR-083 / FR-084 (お問い合わせ再開) / AC-015 / AC-025 / AC-033 |
| 作成日     | 2026-05-17                                                                         |
| 版数      | v1.0                                                                               |
| ステータス   | 承認済                                                                                |

### 1.2 1. 対象範囲

| 種別     | ID                                                     | 名称                          |
|--------|--------------------------------------------------------|-----------------------------|
| 機能     | FR-150～156                                             | ウィジェット設定 / 配信 / 許可ドメイン / 公開 |
| 機能     | FR-083 / FR-084                                        | お問い合わせ再開 (SCR-027)          |
| 機能     | FR-194                                                 | レート制限契約別                    |
| 画面     | SCR-014                                                | ウィジェット表示                    |
| 画面     | SCR-027                                                | お問い合わせ再開                    |
| API    | /widget/v1/bootstrap/widget/v1/ask/widget/v1/reentry/* | ウィジェット API                  |
| デプロイ単位 | pages-widget worker-widget-api                         | ウィジェット配信基盤                  |

### 1.3 2. 収録ロジック・対応章

| 元章      | 元タイトル                          | 概要                               |
|---------|--------------------------------|----------------------------------|
| § 2.2   | コンポーネント詳細責務                    | pages-widget / worker-widget-api |
| § 2.3.2 | ウィジェット API (end_user) リクエストフロー | bootstrap → ask                  |

| 元章                    | 元タイトル                     | 概要                             |
|-----------------------|---------------------------|--------------------------------|
| § 3.3.2               | worker-widget-api モジュール構成 | routes / handlers / middleware |
| § 6 SCR-014 / SCR-027 | 画面詳細設計                    | ウィジェット表示 / お問い合わせ再開（正本は基本設計）   |
| § 7                   | 機能詳細設計（ウィジェット関連）          | 公開 / 許可ドメイン / レート制限（正本は基本設計）   |
| § 13.1.2              | ウィジェット応答経路の最適化            | KV 60s キャッシュ / 埋め込み事前計算        |

## 1.4 3. 詳細設計本文

### 1.4.1 3.1 ウィジェット API リクエストフロー

sequenceDiagram

```

participant E as エンドユーザー
participant W as widget.js (iframe 内)
participant API as worker-widget-api
participant K as KV (allowed_domains / threshold / session)
participant D as D1
participant AI as Workers AI

E->>W: ページ表示時にロード
W->>API: POST /widget/v1/bootstrap (pk_live_xxx, Origin)
API->>K: GET allowed_domains:{project_id}
API->>D: SELECT projects (キャッシュミス時)
API->>K: SET widget-session:{sid} (TTL 1h)
API-->>W: { session_token, project_config }
E->>W: 質問入力 → 送信
W->>API: POST /widget/v1/ask { question, session_token }
API->>D: FTS5 検索 (faq_search_fts)
API->>AI: 推論 (質問 + FAQ 抜粋)
API->>K: GET ai_threshold:{owner_account_id}:{project_id}
API->>D: INSERT question_logs (metering_billable=...)
API-->>W: { type: "answered" | "unanswered" | "error", ... }

```

### 1.4.2 3.2 配信構成

- **pages-widget**: widget.js および iframe コンテンツ配信。CSP/HSTS 設定。
- **worker-widget-api**: ウィジェット用 API (/widget/v1/\*)。bootstrap → session token 認証。
- **pages-public**: SCR-027 等の公開ページ配信。Turnstile 統合。

### 1.4.3 3.3 実装モジュール構成

```

worker-widget-api/src/
├── index.ts
├── routes/
│   ├── bootstrap.ts      # POST /widget/v1/bootstrap
│   ├── ask.ts            # POST /widget/v1/ask
│   ├── inquiries.ts      # /widget/v1/inquiries/*
│   ├── chat-rooms.ts     # /widget/v1/chat-rooms/*
│   └── reentry.ts        # SCR-027 連携
├── handlers/
├── repository/
├── adapter/
│   └── workers-ai-answer-provider.ts
├── middleware/
│   ├── verify-widget-key.ts # pk_live_xxx の検証 + Origin 一致
│   ├── widget-session.ts   # session_token 検証
│   ├── rate-limit.ts       # 50/min 警告 / 60/min 拒否
│   └── audit.ts
└── lib/

```

#### 1.4.4 3.4 性能目標 (NFR-101 / NFR-102)

| API                            | p95 目標   | 達成方策                                     |
|--------------------------------|----------|------------------------------------------|
| POST /widget/v1/bootstrap      | < 200ms  | KV キャッシュ (60s) 優先、D1 ヒット時のみフォールバック       |
| POST /widget/v1/ask (FAQ ヒット)  | < 1000ms | FTS5 検索 + Workers AI バインディング内呼出、最大 5 FAQ |
| POST /widget/v1/ask (FAQ miss) | < 500ms  | AI 推論スキップ                                |

#### 1.4.5 3.5 ウィジェット応答経路の最適化

- KV 60s キャッシュ: `project_key`, `allowed_domains`, `ai_threshold`
- 埋め込みベクトル: FAQ 公開時に事前計算、KV または `faq_embeddings` テーブル保存
- AI モデル: `@cf/meta/llama-3.1-8b-instruct` を第一選択 (早い)、品質要件で `llama-3.1-70b` に切替可能

#### 1.4.6 3.6 AI 推論タイムアウト + フォールバック

```
const inferencePromise = provider.answer(input);
const timeoutPromise = new Promise<never>((_, reject) =>
  setTimeout(() => reject(new Error('AI_TIMEOUT')), 5000),
);
try {
  const result = await Promise.race([inferencePromise, timeoutPromise]);
  // ...
} catch (e) {
  if ((e as Error).message === 'AI_TIMEOUT') {
    // unanswered + 管理者ユーザー誘導
    return { type: 'unanswered', reason: 'ai_timeout' };
  }
  throw e;
}
```

#### 1.4.7 3.7 レート制限 (FR-194 / AC-033)

ウィジェット質問レートは 50/min (警告) / 60/min (拒否、429 `RATE_LIMITED` + Retry-After 付)。同時並列はオーナー 10 / グローバル 200。詳細は [DD12\\_利用量計測・課金.md](#) § 3.1 参照。

#### 1.4.8 3.8 SCR-027 お問い合わせ再開フロー

エンドユーザーがメール内リンク (再入室トークン) を踏むと SCR-027 に遷移し、トークン検証後に既存チャット部屋へ復帰する。再入室トークン仕様は [DD08\\_トークン発行・検証.md](#) § 3.4 を参照。

#### 1.4.9 3.9 関連する横断設計

- AI 回答: [DD03\\_AI 回答パイプライン.md](#)
- しきい値: [DD04\\_AI しきい値 3 階層適用.md](#)
- 個別チャット: [DD06\\_個別チャット.md](#)
- 監査ログ: ウィジェットからの操作は `widget.ask/widget.session.start` 等で記録 (PII マスク)

### 1.5 4. 関連設計

| 種別     | 参照先                     |
|--------|-------------------------|
| 要件     | ../01_要件定義/index.md     |
| 基本設計   | ../02_基本設計/index.md     |
| 画面設計   | ../02_基本設計/01_画面設計.md   |
| API 設計 | ../02_基本設計/02_API 設計.md |
| 運用設計   | ../04_運用設計/index.md     |
| 将来対応   | ../05_future/index.md   |

| 種別    | 参照先                                                                                                     |
|-------|---------------------------------------------------------------------------------------------------------|
| 関連 DD | DD03_AI 回答パイプライン.md / DD04_AI しきい値 3 階層適用.md / DD06_ 個別チャット.md / DD08_ トークン発行・検証.md / DD12_ 利用量計測・課金.md |

## 1.6 5. テスト観点

| AC ID  | テスト ID            | テスト方式       | テストファイル                                                |
|--------|-------------------|-------------|--------------------------------------------------------|
| AC-015 | e2e-widget-001    | E2E         | apps/widget/e2e/bootstrap.spec.ts                      |
| AC-025 | e2e-reentry-001   | E2E         | apps/widget/e2e/reentry.spec.ts                        |
| AC-033 | it-rate-limit-001 | Integration | workers/widget-api/test/integration/rate-limit.test.ts |

### 1.6.1 5.1 ウィジェット E2E 例

```
test('ウィジェット質問が answered になる', async ({ page }) => {
  await page.goto('https://test-site.example.com/'); // ウィジェット埋込テストページ
  await page.frameLocator('iframe.widget').locator('button.trigger').click();
  await page.frameLocator('iframe.widget').locator('textarea').fill('返品方法を教えて');
  await page.frameLocator('iframe.widget').locator('button[type=submit]').click();
  await expect(page.frameLocator('iframe.widget').locator('.answer')).toContainText('返品');
});
```

### 1.6.2 5.2 負荷試験

| シナリオ            | 構成                                  | 目的                   |
|-----------------|-------------------------------------|----------------------|
| (S1) 均等分布       | 200 契約 × 50 FAQ 平均、ask 100 RPS 全体   | ベースライン性能             |
| (S2) 偏在         | 1 契約 10,000 FAQ + 199 契約 × 25 FAQ   | 大規模契約時の FTS5 / D1 限界 |
| (S3) 急増         | 50 → 200 契約 / 5 分で線形増加              | スケール時のオートスケール反応      |
| (S4) AI 高並列     | 100 契約 × ask 5 RPS、AI 推論 200 並列上限到達 | AI 並列上限・タイムアウト挙動     |
| (S5) ピーク(オプション) | 月次キャンペーン想定、200 → 400 RPS スパイク       | エラーバジェット消費量検証        |

合格基準: 全シナリオで p95 ☒ § 3.4 目標値 + http\_req\_failed < 1%。

### 1.6.3 5.3 その他観点

| 観点  | 内容                                                                            |
|-----|-------------------------------------------------------------------------------|
| 単体  | verifyWidgetKey の pk_live_xxx + Origin 一致 / widgetSession の session_token TTL |
| 結合  | bootstrap → ask の一連の流れ / Workers AI タイムアウト 5000ms 時の unanswered               |
| 異常系 | 不正 Origin / 期限切れ session_token / 60/min 超過時 429                               |
| 境界値 | レート制限 50/60 ぴったり / AI タイムアウト 5000ms ぴったり                                      |
| 性能  | p95 bootstrap < 200ms / ask (hit) < 1000ms / (miss) < 500ms                   |

## 1.7 6. 未確定事項・確認事項

| 確認事項 ID | 確認内容                | 優先度 | ステータス |
|---------|---------------------|-----|-------|
| -       | v1.0 リリース時点で全項目確定済み | 低   | 確認済   |