

Contents

1 DD13: ウィジェット配信	1
1.1 0. 文書情報	1
1.2 1. 対象範囲	1
1.3 2. 収録ロジック・対応章	1
1.4 3. 詳細設計本文	2
1.4.1 3.1 ウィジェット API リクエストフロー	2
1.4.2 3.2 配信構成	2
1.4.3 3.3 実装モジュール構成	2
1.4.4 3.4 性能目標 (NFR-101 / NFR-102)	3
1.4.5 3.5 ウィジェット応答経路の最適化	3
1.4.6 3.6 AI 推論タイムアウト + フォールバック	3
1.4.7 3.7 レート制限 (FR-194 / AC-033)	3
1.4.8 3.8 SCR-027 お問い合わせ再開フロー	3
1.4.9 3.9 関連する横断設計	3
1.5 4. 関連設計	3
1.6 5. テスト観点	4
1.6.1 5.1 ウィジェット E2E 例	4
1.6.2 5.2 負荷試験	4
1.6.3 5.3 その他観点	4
1.7 6. 未確定事項・確認事項	4

1 DD13: ウィジェット配信

1.1 0. 文書情報

項目	内容
文書名	DD13: ウィジェット配信
詳細設計 ID	DD13
対象システム	FAQ AI ウィジェット SaaS / メインシステム
関連機能 ID	FR-150～156 (ウィジェット設定 / 配信) / FR-083 / FR-084 (お問い合わせ再開) / AC-015 / AC-025 / AC-033
作成日	2026-05-17
版数	v1.0
ステータス	承認済

1.2 1. 対象範囲

種別	ID	名称
機能	FR-150～156	ウィジェット設定 / 配信 / 許可ドメイン / 公開
機能	FR-083 / FR-084	お問い合わせ再開 (SCR-027)
機能	FR-194	レート制限契約別
画面	SCR-014	ウィジェット表示
画面	SCR-027	お問い合わせ再開
API	/widget/v1/bootstrap/widget/v1/ask/widget/v1/reentry/*	ウィジェット API
デプロイ単位	pages-widget worker-widget-api	ウィジェット配信基盤

1.3 2. 収録ロジック・対応章

元章	元タイトル	概要
§ 2.2	コンポーネント詳細責務	pages-widget / worker-widget-api
§ 2.3.2	ウィジェット API (end_user) リクエストフロー	bootstrap → ask

元章	元タイトル	概要
§ 3.3.2	worker-widget-api モジュール構成	routes / handlers / middleware
§ 6 SCR-014 / SCR-027	画面詳細設計	ウィジェット表示 / お問い合わせ再開（正本は基本設計）
§ 7	機能詳細設計（ウィジェット関連）	公開 / 許可ドメイン / レート制限（正本は基本設計）
§ 13.1.2	ウィジェット応答経路の最適化	KV 60s キャッシュ / 埋め込み事前計算

1.4 3. 詳細設計本文

1.4.1 3.1 ウィジェット API リクエストフロー

sequenceDiagram

```

participant E as エンドユーザー
participant W as widget.js (iframe 内)
participant API as worker-widget-api
participant K as KV (allowed_domains / threshold / session)
participant D as D1
participant AI as Workers AI

E->>W: ページ表示時にロード
W->>API: POST /widget/v1/bootstrap (pk_live_xxx, Origin)
API->>K: GET allowed_domains:{project_id}
API->>D: SELECT projects (キャッシュミス時)
API->>K: SET widget-session:{sid} (TTL 1h)
API-->>W: { session_token, project_config }
E->>W: 質問入力 → 送信
W->>API: POST /widget/v1/ask { question, session_token }
API->>D: FTS5 検索 (faq_search_fts)
API->>AI: 推論 (質問 + FAQ 抜粋)
API->>K: GET ai_threshold:{contract_owner_user_id}:{project_id}
API->>D: INSERT question_logs (metering_billable=...)
API-->>W: { type: "answered" | "unanswered" | "error", ... }

```

1.4.2 3.2 配信構成

- **pages-widget**: widget.js および iframe コンテンツ配信。CSP/HSTS 設定。
- **worker-widget-api**: ウィジェット用 API (/widget/v1/*)。bootstrap → session token 認証。
- **pages-public**: SCR-027 等の公開ページ配信。Turnstile 統合。

1.4.3 3.3 実装モジュール構成

```

worker-widget-api/src/
├── index.ts
├── routes/
│   ├── bootstrap.ts      # POST /widget/v1/bootstrap
│   ├── ask.ts            # POST /widget/v1/ask
│   ├── inquiries.ts      # /widget/v1/inquiries/*
│   ├── chat-rooms.ts     # /widget/v1/chat-rooms/*
│   └── reentry.ts        # SCR-027 連携
├── handlers/
├── repository/
├── adapter/
│   └── workers-ai-answer-provider.ts
├── middleware/
│   ├── verify-widget-key.ts # pk_live_xxx の検証 + Origin 一致
│   ├── widget-session.ts   # session_token 検証
│   ├── rate-limit.ts       # 50/min 警告 / 60/min 拒否
│   └── audit.ts
└── lib/

```

1.4.4 3.4 性能目標 (NFR-101 / NFR-102)

API	p95 目標	達成方策
POST /widget/v1/bootstrap	< 200ms	KV キャッシュ (60s) 優先、D1 ヒット時のみフォールバック
POST /widget/v1/ask (FAQ ヒット)	< 1000ms	FTS5 検索 + Workers AI バインディング内呼出、最大 5 FAQ
POST /widget/v1/ask (FAQ miss)	< 500ms	AI 推論スキップ

1.4.5 3.5 ウィジェット応答経路の最適化

- KV 60s キャッシュ: `project_key, allowed_domains, ai_threshold`
- 埋め込みベクトル: FAQ 公開時に事前計算、KV または `faq_embeddings` テーブル保存
- AI モデル: `@cf/meta/llama-3.1-8b-instruct` を第一選択 (早い)、品質要件で `llama-3.1-70b` に切替可能

1.4.6 3.6 AI 推論タイムアウト + フォールバック

```
const inferencePromise = provider.answer(input);
const timeoutPromise = new Promise<never>((_, reject) =>
  setTimeout(() => reject(new Error('AI_TIMEOUT')), 5000),
);
try {
  const result = await Promise.race([inferencePromise, timeoutPromise]);
  // ...
} catch (e) {
  if ((e as Error).message === 'AI_TIMEOUT') {
    // unanswered + 管理者ユーザー誘導
    return { type: 'unanswered', reason: 'ai_timeout' };
  }
  throw e;
}
```

1.4.7 3.7 レート制限 (FR-194 / AC-033)

ウィジェット質問レートは 50/min (警告) / 60/min (拒否、429 `RATE_LIMITED` + Retry-After 付)。同時並列はオーナー 10 / グローバル 200。詳細は [DD12_利用量計測・課金.md](#) § 3.1 参照。

1.4.8 3.8 SCR-027 お問い合わせ再開フロー

エンドユーザーがメール内リンク (再入室トークン) を踏むと SCR-027 に遷移し、トークン検証後に既存チャット部屋へ復帰する。再入室トークン仕様は [DD08_トークン発行・検証.md](#) § 3.4 を参照。

1.4.9 3.9 関連する横断設計

- AI 回答: [DD03_AI 回答パイプライン.md](#)
- しきい値: [DD04_AI しきい値 3 階層適用.md](#)
- 個別チャット: [DD06_個別チャット.md](#)
- 監査ログ: ウィジェットからの操作は `widget.ask/widget.session.start` 等で記録 (PII マスク)

1.5 4. 関連設計

種別	参照先
要件	../01_要件定義/index.md
基本設計	../02_基本設計/index.md
画面設計	../02_基本設計/01_画面設計.md
API 設計	../02_基本設計/02_API 設計.md
運用設計	../04_運用設計/index.md
将来対応	../05_future/index.md

種別	参照先
関連 DD	DD03_AI 回答パイプライン.md / DD04_AI しきい値 3 階層適用.md / DD06_ 個別チャット.md / DD08_ トークン発行・検証.md / DD12_ 利用量計測・課金.md

1.6 5. テスト観点

AC ID	テスト ID	テスト方式	テストファイル
AC-015	e2e-widget-001	E2E	apps/widget/e2e/bootstrap.spec.ts
AC-025	e2e-reentry-001	E2E	apps/widget/e2e/reentry.spec.ts
AC-033	it-rate-limit-001	Integration	workers/widget-api/test/integration/rate-limit.test.ts

1.6.1 5.1 ウィジェット E2E 例

```
test('ウィジェット質問が answered になる', async ({ page }) => {
  await page.goto('https://test-site.example.com/'); // ウィジェット埋込テストページ
  await page.frameLocator('iframe.widget').locator('button.trigger').click();
  await page.frameLocator('iframe.widget').locator('textarea').fill('返品方法を教えて');
  await page.frameLocator('iframe.widget').locator('button[type=submit]').click();
  await expect(page.frameLocator('iframe.widget').locator('.answer')).toContainText('返品');
});
```

1.6.2 5.2 負荷試験

シナリオ	構成	目的
(S1) 均等分布	200 契約 × 50 FAQ 平均、ask 100 RPS 全体	ベースライン性能
(S2) 偏在	1 契約 10,000 FAQ + 199 契約 × 25 FAQ	大規模契約時の FTS5 / D1 限界
(S3) 急増	50 → 200 契約 / 5 分で線形増加	スケール時のオートスケール反応
(S4) AI 高並列	100 契約 × ask 5 RPS、AI 推論 200 並列上限到達	AI 並列上限・タイムアウト挙動
(S5) ピーク(オプション)	月次キャンペーン想定、200 → 400 RPS スパイク	エラーバジェット消費量検証

合格基準: 全シナリオで p95 ☒ § 3.4 目標値 + http_req_failed < 1%。

1.6.3 5.3 その他観点

観点	内容
単体	verifyWidgetKey の pk_live_xxx + Origin 一致 / widgetSession の session_token TTL
結合	bootstrap → ask の一連の流れ / Workers AI タイムアウト 5000ms 時の unanswered
異常系	不正 Origin / 期限切れ session_token / 60/min 超過時 429
境界値	レート制限 50/60 ぴったり / AI タイムアウト 5000ms ぴったり
性能	p95 bootstrap < 200ms / ask (hit) < 1000ms / (miss) < 500ms

1.7 6. 未確定事項・確認事項

確認事項 ID	確認内容	優先度	ステータス
-	v1.0 リリース時点で全項目確定済み	低	確認済