

Contents

1	監視設計 (メインシステム)	1
1.1	0. 文書情報	1
1.2	1. 監視方針	1
1.3	2. SLO 表 (参照: NFR-806)	1
1.4	3. KPI 監視 9 項目 (参照: NFR-804)	2
1.5	4. 監視ダッシュボード (運営者向け)	2
1.6	5. エスカレーション 3 段階	2
1.6.1	5.1 エスカレーションパス (意思決定責任者)	2
1.7	6. ログ retention 整合性検証	3
1.8	7. アラートルール定義	3
1.9	8. オンコール体制	3
1.10	9. 関連設計	3
1.11	10. 未確定事項・確認事項	4

1 監視設計 (メインシステム)

1.1 0. 文書情報

項目	内容
文書名	監視設計 (メインシステム)
運用 ID	OPS-01
対象システム	FAQ AI ウィジェット SaaS / メインシステム
作成日	2026-05-17
版数	v1.0
ステータス	承認済

1.2 1. 監視方針

項目	内容
計測基盤	Cloudflare Workers Analytics + Workers Logs + 外部監視 (Datadog 等)。メトリクスは 5 分窓集計、日次評価
ダッシュボード	Grafana(外部) に Cloudflare Workers Analytics + IF #8 メトリクスを集約
主要パネル	SLO 達成率 / 5xx 率 / AI p95 / Queue 滞留 / 通知配信率 / DB 容量
監視粒度	ウィジェット系 = 30 秒 / 課金系 = 5 分 / 月次系 = 1 時間
burn-rate 監視	短期 (1h) と長期 (24h) のエラーバジェット消費率を二重監視
自動復旧	Worker 自動再デプロイ / Queue リトライ / サーキットブレーカ。手動介入が必要な場合は SYSTEM_NOTICE で運営者通知

1.3 2. SLO 表 (参照: NFR-806)

指標	SLO 目標	エラーバジェット	自動復旧アクション
公開ウィジェット可用性	99.9%	月 43.2 分	Worker 自動再デプロイ、サーキットブレーカ
公開 API 5xx 率	< 0.5%	-	5 分間で 1% 超過時に運営者アラート
管理画面可用性	99.5%	月 216 分	同上
API p95 レイテンシ	各 NFR 値以下 (§ 11.1 参照)	-	一時的超過時に Workers 再起動
通知配信失敗率	< 1%	-	DLQ 投入時にアラート、Resend 切替候補通知
Workers AI 応答時間 p95	< 2.0s	-	フォールバックモデルへ手動切替

1.4 3. KPI 監視 9 項目 (参照: NFR-804)

KPI	しきい値	通知先	重要度
(a) 契約別 5xx 率	> 1%(5 分窓)	Slack #ops-warn	normal
(b) AI 推論 p95	> 2.5s	Slack #ops-warn	normal
(b') AI 推論 p95	> 5s	PagerDuty	high
(c) Queue DLQ 滞留	> 100 件	PagerDuty	high
(d) 通知バウンス率	> 5%(1h)	Slack + メール	normal
(e) 通知苦情率	> 0.1%(1h)	PagerDuty	high
(f) 課金 Webhook 失敗	連続 3 件	PagerDuty	critical
(g) AI 回答可能率	直前比 -5pt	Slack #ai-quality	high
(h) D1 容量	> 80%(8GB)	Slack #ops-warn	normal

1.5 4. 監視ダッシュボード (運営者向け)

指標	内容
稼働状態	サービス稼働状況
API 成功率	5xx 率、4xx 率 (NFR-804 (a))
レイテンシ	API 別 p50 / p95 (NFR-101~106)
Queue 滞留	バックログ件数 (NFR-804 (c))
通知配信状況	送信数、失敗、バウンス、苦情 (NFR-804 (d) (e))
契約別利用量	質問数、チャット数
不正検知	許可ドメイン外、レート超過 (FR-195)
レート制限上書き状況	owner_quota_overrides の有効件数、しきい値超過契約、有効期限切迫の上書き
AI 品質メトリクス	回答可能率・解決率・矛盾理由コード分布・PII 検出件数 (NFR-804 (g))
D1 容量	NFR-804 (h)、8GB 警告
連携 IF 状況	IF #1~#12 の送受信成功率、DLQ 滞留、リプレイ実行数

1.6 5. エスカレーション 3 段階

重要度	通知方法	一次対応
normal	Slack #ops-warn	営業時間内対応
high	Slack + メール (オンコール宛)	30 分以内対応
critical	PagerDuty 即時 + 電話	15 分以内対応

1.6.1 5.1 エスカレーションパス (意思決定責任者)

未対応時間が一定を超えた場合、自動でエスカレーション。PagerDuty の Escalation Policy で実装。

critical 検知

- ↓ 即時
- on-call (第 1 階層) 個人携帯 + PagerDuty
- ↓ 15 分未対応 / 拒否
- on-call backup (第 2 階層) 個人携帯
- ↓ さらに 15 分未対応
- on-call manager (第 3 階層) + 経営陣 (CTO / SRE Lead)
- ↓ さらに 30 分未対応
- 全社オンコール (Slack #incident-all-hands) + 外部監視ベンダー連絡

high 検知

- ↓ 即時
- on-call (第 1 階層) Slack + メール
- ↓ 30 分未対応
- on-call backup + on-call manager
- ↓ さらに 60 分未対応
- 経営陣エスカレーション

階層	役割	意思決定責任
第1階層 (on-call)	一次切り分け / runbook 実行	5分以内に Ack、原因切り分け開始
第2階層 (on-call backup)	第1階層が応答しない場合の代替	同上 (一次対応の継続)
第3階層 (on-call manager)	リソース調整 / 外部連絡可否	サービス縮退 / 計画停止判断、契約周知の判断
経営陣 (CTO / SRE Lead)	重大インシデント対応・ステークホルダー報告	データ損失リスク評価、顧客告知のトーン決定

- **手順書:** PagerDuty の Escalation Policy 設定は `infra/pagerduty/escalation-policy.tf`(Terraform) で IaC 化し、MVP 環境へ適用する
- **重要度の昇格基準:** high が 90 分継続 → critical に手動昇格 (on-call manager の判断)
- **回復通知:** 解決時は同一チャンネルに **RESOLVED:** プレフィクス付きで告知、`incident-id` で紐付け

1.7 6. ログ retention 整合性検証

ログ種別ごとに retention が異なるため (`question_logs` 1 年 / `error_logs` 180 日 / `audit_logs` 1y/5y/7y 区分)、削除タイミング不整合が検知できるよう **retention purge cron** が両者を同期削除し、不整合検知時にアラート発火する。

- **同期削除:** §14.1.9 `retentionCleanup` で `question_logs` / `chat_messages` / `notification_logs` / `error_logs` / `access_tokens` を同一ジョブ内で削除 (1 transaction)
- **不整合検知バッチ:** 日次 JST 04:30 `RetentionConsistencyChecker` (新設):
 - `question_logs` 中で 365 日超過の行が残っていないか
 - `error_logs` 中で 180 日超過の行が残っていないか
 - `chat_rooms` (1 年) と `chat_messages` (孤児チェック) の親子整合
 - `audit_logs` の `retention_class='1y'` で 1 年超過行が残っていないか
- **検知時のアクション:** `audit_logs` に `retention.inconsistency.detected(5y)` を記録、`#ops-warn` に normal 重要度で通知、運営者 inbox に詳細
- **テスト:** Integration テストで `it-retention-consistency-001` を整備し、意図的な不整合を検知できることを確認

1.8 7. アラートルール定義

Cloudflare Workers Analytics + 外部監視 (Datadog 等) でメトリクスを集約。アラートルール例:

- ```
- alert: TenantErrorRateHigh
 expr: rate(http_requests_total{status=~"5.."}[5m]) / rate(http_requests_total[5m]) > 0.01
 for: 5m
 labels: { severity: normal }
 annotations: { summary: " 契約 {{$labels.owner_account_id}} の 5xx 率 > 1%" }

- alert: AiP95Critical
 expr: histogram_quantile(0.95, ai_inference_duration_seconds_bucket) > 5.0
 for: 5m
 labels: { severity: high }
...
```

## 1.9 8. オンコール体制

NFR-810 に従い、24/7 オンコールを 2 名以上配置 (MVP は 1 名 + バックアップ)。シフトはローテーション。連休前の引継ぎ runbook を整備。

## 1.10 9. 関連設計

| 種別   | 参照先                 |
|------|---------------------|
| 要件   | ../01_要件定義/index.md |
| 基本設計 | ../02_基本設計/index.md |
| 詳細設計 | ../03_詳細設計/index.md |

| 種別     | 参照先                                                              |
|--------|------------------------------------------------------------------|
| 将来対応   | ../05_future/index.md                                            |
| 関連 NFR | NFR-803 / NFR-804 / NFR-806 / NFR-810 / AC-020 / AC-029 / AC-046 |

## 1.11 10. 未確定事項・確認事項

| 確認事項 ID | 確認内容                | 優先度 | ステータス |
|---------|---------------------|-----|-------|
| -       | v1.0 リリース時点で全項目確定済み | 低   | 確認済   |