

Contents

1	FUT02: 検索・AI 強化	1
1.1	0. 文書情報	1
1.2	1. 概要	1
1.3	2. 関連要件・候補	1
1.3.1	2.1 要件候補 (将来 FR)	1
1.3.2	2.2 基本設計論点	2
1.3.3	2.3 詳細設計バックログ	2
1.4	3. 影響範囲	3
1.5	4. 実施条件	3
1.6	5. 関連設計	3
1.7	6. 未確定事項・確認事項	3

1 FUT02: 検索・AI 強化

1.1 0. 文書情報

項目	内容
文書名	FUT02: 検索・AI 強化
将来対応 ID	FUT-02
対象システム	FAQ AI ウィジェット SaaS / メインシステム
作成日	2026-05-17
版数	v1.0
ステータス	検討中 (MVP 外)

1.2 1. 概要

項目	内容
概要	MVP では SQLite ベース全文検索 + バッチ AI 応答 + 第 1 層 (正規表現) PII 検出 + 簡易ルールベース矛盾検知に限定している検索・AI 領域について、Post-MVP で意味検索 / ストリーミング応答 / NER 第 2 層 / 意味類似度ベース矛盾検知 / プロンプトカスタマイズへ段階拡張する。
背景	FAQ 検索体感と AI 応答品質はサービス価値の中核であり、ベータ～GA フェーズで体感速度・精度・誤検出率を計測可能な閾値まで引き上げる必要がある。
期待効果	検索精度向上による解決率改善、AI 応答の体感速度向上、PII 漏洩リスク低減、矛盾 FAQ の早期検出、契約単位のトーン調整。
優先度 (将来対応内)	中
想定時期	T2(ベータ判定まで)～T3(GA 判定まで)

1.3 2. 関連要件・候補

1.3.1 2.1 要件候補 (将来 FR)

1.3.1.1 検索・AI

ID	要件候補	MVP の前提	判定時期	判定基準 / 完了条件
FUT-REQ-AI-001	Vectorize 連携による意味検索	SQLite ベース全文検索のみ	GA	契約別検索精度要望件数、検索品質、コスト試算をもとに導入可否を判定

ID	要件候補	MVP の前提	判定時期	判定基準 / 完了条件
FUT-REQ-AI-002	SSE / ストリーミング応答	AI 回答はバッチ応答	GA	体感速度改善、Cloudflare Workers の制約、タイムアウト・課金影響をもとに判定
FUT-REQ-AI-003	PII 検出 NER 第 2 層	第 1 層 (正規表現) のみ	ベータ	Cloudflare 内で完結し、検出再現率 90% 以上、適合率 95% 以上、推論レイテンシ 100ms 未満
FUT-REQ-AI-004	矛盾検知の意味類似度化	同一カテゴリ + キーワード反転による簡易ルールベース	ベータ / GA	False Positive 率 10% 以下、検出再現率 80% 以上、推論レイテンシ 200ms 未満

1.3.2 2.2 基本設計論点

1.3.2.1 検索・AI

項目	基本設計で具体化すること	関連 Future 要件
Vectorize 連携	SQLite 全文検索との併用方式、インデックス同期、検索結果ランキング、フォールバック条件	FUT-REQ-AI-001
SSE / ストリーミング応答	ウィジェットの表示状態、途中失敗時の UX、再試行、課金・メータリング確定タイミング	FUT-REQ-AI-002
PII NER 第 2 層	第 1 層との判定順序、誤検出報告フロー、ルール更新、過去データ修正有無	FUT-REQ-AI-003
矛盾検知の意味類似度化	埋め込み生成タイミング、検知結果の UI 表示、管理者による無視・解消状態	FUT-REQ-AI-004

1.3.3 2.3 詳細設計バックログ

1.3.3.1 実装設計バックログ (関連分)

ID	対象	実装設計で具体化すること	関連 Future 要件
FUT-DD-AI-001	Vectorize 連携	埋め込み生成 Queue、インデックス同期、再生成、検索 API フォールバック、コストメトリクス	FUT-REQ-AI-001
FUT-DD-AI-002	SSE / ストリーミング応答	SSE endpoint、chunk 保存方針、途中失敗、メータリング確定、クライアント再接続	FUT-REQ-AI-002
FUT-DD-AI-003	PII NER 第 2 層	model adapter、推論タイムアウト、判定統合、誤検出報告反映、評価データセット	FUT-REQ-AI-003
FUT-DD-AI-004	矛盾検知意味類似度化	embedding table、類似度計算 Worker、しきい値、false positive 学習、再実行ジョブ	FUT-REQ-AI-004

1.3.3.2 API / Worker 候補 (関連分)

領域	候補
Vectorize	FaqEmbeddingSyncWorker、POST /internal/v1/faqs/{id}/embedding-refresh、検索 API の mode=semantic
SSE / リアルタイム	GET /widget/v1/questions/{id}/stream、GET /api/v1/inbox/stream、fallback polling
PII NER	PiiNerWorker、POST /internal/v1/pii/evaluate、誤検出報告反映ジョブ

1.3.3.3 テスト・検証候補 (関連分)

領域	検証項目
Vectorize	embedding 欠落時 fallback、同期遅延、ランキング品質、コスト上限
SSE	切断・再接続、途中失敗、二重課金防止、モバイルブラウザ互換

1.4 3. 影響範囲

種別	影響内容
要件	FR-300(検索方式)、FR-323 / FR-340(応答方式)、FR-054(矛盾検知)、FR-059(AI 品質テストセット)、FR-060(PII 検出層)
画面	ウィジェット応答表示(ストリーミング)、FAQ 管理画面(矛盾検知結果表示)、運営者・利用者の PII 誤検出報告画面、契約別プロンプト選択 UI(SCR-028 アカウント設定オーナーセクション周辺で具体化)
API	GET /widget/v1/questions/{id}/stream、GET /api/v1/inbox/stream、POST /internal/v1/faqs/{id}/embedding-refresh、POST /internal/v1/pii/evaluate、検索 API の mode=semantic パラメータ
テーブル	embedding 保管テーブル、PII 検出結果テーブル拡張、プロンプトテンプレート契約上書きテーブル(Future で具体化)
運用	Vectorize コストメトリクス監視、SSE 接続観測、NER モデル更新フロー、品質テストセット運用、プロンプト注入回帰 AC-035 自動実行

1.5 4. 実施条件

項目	内容
実施判断条件	NER 第 2 層は検出再現率 90%/適合率 95%/レイテンシ 100ms 未満、矛盾検知意味類似度化は FP 率 10% 以下 / 再現率 80% 以上 / レイテンシ 200ms 未満、Vectorize はコスト試算 + 検索品質、SSE は Cloudflare Workers タイムアウト・課金影響
期限	T2(PII NER 第 2 層、矛盾検知の初期評価)、T3(Vectorize、SSE、プロンプトカスタマイズ)
依存関係	NFR-319(チャット暗号化)と embedding 生成パイプラインの整合、メータリング(FUT-04 プラン別機能)との確定タイミング整合、共有 IF #1~#12(Cloudflare AI / Workers 連携)の安定性

1.6 5. 関連設計

種別	参照先
要件	../01_要件定義/index.md
基本設計	../02_基本設計/index.md
詳細設計	../03_詳細設計/index.md
運用設計	../04_運用設計/index.md
共有概念(正本)	../共有/共有概念.md

1.7 6. 未確定事項・確認事項

確認事項 ID	確認内容	優先度	ステータス
FUT-AI-Q-001	Cloudflare 内で完結する PII NER モデル候補の選定基準と評価データセット作成主管	高	検討中
FUT-AI-Q-002	Vectorize と SQLite 全文検索の併用ランキング・フォールバック条件の確定	高	検討中
FUT-AI-Q-003	SSE 応答の途中失敗時のメータリング確定タイミング(課金二重計上防止)	中	検討中
FUT-AI-Q-004	プロンプトカスタマイズの注入対策(運営者管理プロンプト優先・サニタイズ)	中	検討中